

深度迁移学习辅助的阿尔兹海默氏症早期诊断

金祝新¹ 秦飞巍¹ 方美娥^{1,2*}

¹(杭州电子科技大学计算机学院 浙江 杭州 310018)

²(广州大学计算机科学与教育软件学院 广东 广州 510000)

摘要 目前越来越多的老人正在遭受着阿尔兹海默氏症 AD(Alzheimer's Disease)带来的痛苦。临床研究表明,轻度认知障碍 MCI(mild cognitive impairment)转化为阿尔兹海默氏症的概率很高,但是若能在 MCI 阶段对其进行药物治疗是可以康复的,因此提高根据核磁共振图像 MRI 医学图像诊断的准确率很有必要。由于医学领域的特点,构建带标注信号的一定规模的数据集非常困难,导致现有机器学习/深度学习方法难以应用于医学影像分析以至于深度学习的结果并不理想。采用数据增广方式对原来数据集的规模进行一定数量的扩充。然后采用一种针对 MRI 识别的端到端的深度神经网络分类器(MCINet)。结合迁移学习方式对 MCINet 模型进行有效训练而不至于过拟合。实验结果表明,该方法在较少带标记训练样本的情形下,也获得较高的准确率。

关键词 MRI 医学图像 图像处理 深度学习 迁移学习

中图分类号 TP3 文献标识码 A DOI: 10.3969/j.issn.1000-386x.2019.05.029

DEEP TRANSFER LEARNING-ASSISTED EARLY DIAGNOSIS OF ALZHEIMER'S DISEASE

Jin Zhuxin¹ Qin Feiwei¹ Fang Meie^{1,2*}

¹(School of Computer and Technology, Hangzhou Dianzi University, Hangzhou 310018, Zhejiang, China)

²(School of Computer Science and Educational Software, Guangzhou University, Guangzhou 510000, Guangdong, China)

Abstract At present, more and more elderly people are suffering from Alzheimer's Disease(AD). Clinical studies have shown that mild cognitive impairment(MCI) has a high probability of transforming into AD, but if it can be treated with medication at the stage of MCI, it can be recovered. Therefore, it is necessary to improve the diagnostic accuracy of medical images based on MRI. Because of the characteristics of medical field, it is very difficult to construct a certain scale data set with annotated signals, which makes the existing machine learning/deep learning difficult to apply to medical image analysis, so that the results of deep learning are not ideal. We used data augmentation to expand the size of the original data set. Then we used an end-to-end deep neural network classifier(MCINet) for MRI recognition. And we combined transfer learning to train the MCINet model effectively without over-fitting. The experimental results show that the method has a high accuracy in the case of fewer labeled training samples.

Keywords MRI medical image Image processing Deep learning Transfer learning

0 引言

阿尔兹海默氏症是一种起病隐匿的进行性发展的神经系统退行性疾病,它会导致患者记忆功能的改变,同时认知功能和行为也会受到影响。该病对大脑的损

伤是不可逆的,目前仍没有有效的治疗方案。随着全球人口老龄化、环境恶化的加剧,老年痴呆病患者的数量也在大量增长。轻度认知障碍(MCI)是介于正常衰老 HC(Healthy Control)和痴呆之间的一种中间状态,是一种认知障碍症候群。轻度认知障碍患者被认为是阿尔兹海默氏症患病的高危人群。若对 MCI 向 AD 阶

收稿日期:2018-10-01。国家自然科学基金项目(61502129);浙江省自然科学基金项目(LY17F020025, LQ16F020004);广东省高校省级平台创强项目(2017KTSCX143)。金祝新 硕士生,主研领域:人工智能、医学图像处理。秦飞巍 副教授。方美娥 教授。

段转化患者的可能性进行预测,进而对易发展为 AD 的 MCI 患者采取相应的治疗干预手段,这是延缓 AD 发病的最有效方法。因此 MCI 医学影像的精准识别与分类对于 AD 症的诊疗是至关重要的。

随着机器学习在图像领域取得的出色成绩,研究者们纷纷采取各种机器学习相关算法来建立自动化阿尔茨海默病检测和分类的模型。比如 Brosch 等^[1]开发了一种深度信念网络模型(DBN),使用流形学习来从 MRI 图像中进行 AD 检测。Gray 等^[2]开发了一种多模式分类模型,使用随机森林分类器从 MRI 和 PET 医学图像中检测 AD。Gupta 等^[3]采用 2D 卷积神经网络(CNN)进行 MRI 扫描的切片特征提取。为了提高分类性能,CNN 首先在自然图像的随机片段上用稀疏自动编码器(SAE)进行预训练。Klöppel 等^[4]使用灰质(GM)体素作为特征并训练 SVM 以区分 AD 和 NC 对象。将 MRI 分割为 GM、白质(WM)和 CSF 部分,然后计算它们的体素密度,并将每个体素与 GM、WM 和 CSF 密度的矢量相关联以进行分类。Liu 等^[5]利用 MRI 数据集中的多个选定模板提取多视图特征;然后使用每个模板的组织密度图对每个类中的受试者进行聚类,以便提取每个受试者的编码特征;最后,使用支持向量机(SVM)来进行分类。刘等^[6]开发了一种使用零掩模策略的多模式堆叠自编码器网络。目的是防止丢失图像数据的任何信息,他们还使用 SVM 对从 MRI/PET 数据获得的神经影像特征进行分类。Zu 等^[7]通过多任务特征选择方法提出一种多模态分类模型。特征学习方法是基于不同模态用不同的回归模型,其中标签信息用作正则化器,以减少新特征空间中不同模态的相似主题的差异。然后使用多核 SVM 进行分类。Payan 等^[8]利用稀疏的自动编码器和 3D CNN 模型训练 ADNI 数据集,从而对 AD、MCI 和 HC 患者进行分类。Suk 等^[9]使用多模式深度 BM 从每个选定的 MRI 和 PET 扫描片中提取一个特征,并用 SVM 集合预测 AD。

上述方法能够对 MRI 医学影像进行自动化的识别与分类,节省人力资源和时间开销。然而,由于 AD 医学领域所固有的特点,导致现有许多自动化识别方法的准确率不够高,难以应用于临床实践。首先,受现有医疗环境的限制,获取带标记的高质量大规模 MRI 数据集极为困难,而这对于训练高准确率的自动化分类器非常关键;其次,大多数现有工作都采用从 MRI 或者 PET 医学图像中手工提取特征的方法,这些手工提取特征的方法在医学上的应用不是十分理想的,不仅十分耗时,而且还需要依赖于医学方面的专家;再

者,其中大部分的相关工作都对医学图像做过多的预处理,这样的操作可能破坏图像数据集本身所固有的特征信息,导致准确率降低。

本文提出一种深度迁移学习辅助的阿尔兹海默氏症早期诊断方法。一方面,基于图像分类的理论,采用一种端到端的面向轻度认知障碍 MRI 图像识别的 MCINet 模型,用于辅助 AD 症的早期诊断。该模型不需要对 MRI 医学图像做更深层次的预处理,因而不会过多地损坏/丢失图像原有的信息;另一方面,由于医学图像本身的规模就不大,而基于深度学习的图像分类要想达到高精度的分类结果一般都需要上百万的数据量,故本文利用迁移学习技术,目的是 ImageNet 的权重迁移(transfer)作为网络的初始权重。此外,我们利用数据增广(Data Augmentation)技术对原始 MRI 数据集进行扩充,并选取包含脑部信息最丰富的片数作为训练集,以尽可能地提高数据集的质量,用于神经网络训练。

1 方法概述

在 AD 分类中,最开始的是 Coates 等^[10]提出的单层的特征学习方法,然后是 Bo 等^[11]提出的两层的特征学习方法,一直到目前使用的卷积神经网络^[12],分类方法也一直在改进。但是由于缺少高质量的标注的训练样本,因此训练出来的模型可能会过拟合,或者准确率不高。本文算法的具体方法框架如图 1 所示。

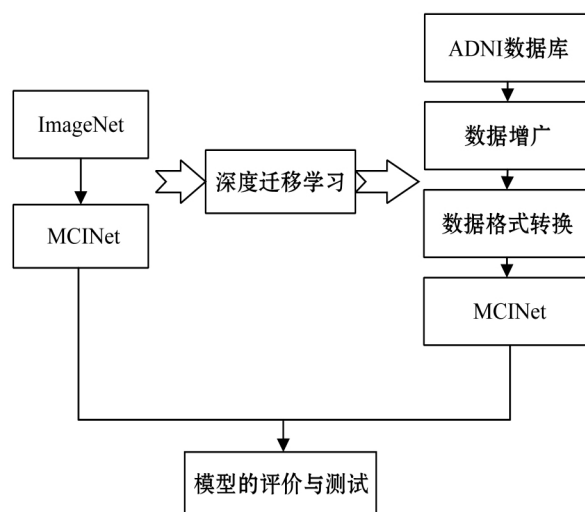


图 1 方法概述框图

具体步骤如下:

步骤 1 根据 AD 领域的知识,基于卷积神经网络,采用了一种面向 MCI 图像识别的深度神经网络分类器。

步骤 2 在大型公共数据集 ImageNet 得到预训练

模型。

步骤 3 对原始 MRI 数据集进行处理, 先进行文件格式的转换, 将原始的 MRI 数据格式转换成实验所要求的实验的训练集, 然后甄选满足 AD 特征的 MRI 数据集。MRI 数据的规模比较小故需先对数据进行数据增广。

步骤 4 将预训练模型的前两层卷积层根据迁移学习的技术迁移到 MCINet 模型中, 然后使用 MRI 医学图像数据集训练调整该模型的剩余层数, 从而使得神经网络学得的参数更加逼近全局最优解。

步骤 5 模型评价: 主要从两个方面来对模型进行评价, 一是在不引用迁移学习算法而完全采用 MCINet 模型来训练数据集, 二是将迁移学习与 MCINet 模型相结合来训练数据集。然后根据训练的结果, 对两种方法进行评估。

2 输入模式生成

本文的实验数据集是来自于 ADNI 网站上的 MRI 医学图像。每个原始的 MRI 图像都是 $256 \times 256 \times 100$, 其中 100 为片数。图 2 为 HC、AD、MCI 某一特征的 MRI 医学图像。




图 2 MRI 医学图像

表 1 所示的是本实验 MRI 数据集的信息其中包含患者的人数、年龄、性别和切片的数量。

表 1 MRI 数据集信息

类别	类别人数	年龄	性别(男/女)	切片数量
MCI	446	74.47	250/196	44 600
AD	267	76.17	137/130	26 700
HC	574	78.50	285/289	57 400

由于 MRI 医学图像记录的是整个脑部的信息, 实验需选取其中跟阿尔兹海默症联系紧密区域的图像, 即选取信息含量丰富的片数作为训练集, 这会大大提高分类的准确率。本文根据 Liu 等^[6]利用统计分析法选出 AD 分类最重要的片数, 再结合医学专家的建议选取如图 3 所示的三种不同特征的 MRI 图片作为训练集。



图 3 不同特征图像

2.1 数据增广

深度学习本身就是建立在大数据的基础上, 一般数据量越大准确率越高。而传统学习算法的最大区别就在于当它达到一定的数据量后准确率会呈现一个收敛的状态。所以基于深度学习的图像分类就要考虑如何在有限的数据库中习得有效的特征。一般, 模型的质量与数据的质量和数量有着密切的关系, 医学图像又有着高依赖成像设备和成像环境, 图像种类多差异, 很难融合, 像素大分辨率低, 生物个体存在差异等特点所以难以训练和识别。如表 2 所示, 本实验在数据集数量上进行了扩充, 由于 ADNI 网站上的人数非常有限, 故本实验将同一个主体不同时间采集的 MRI 图像也考虑进去, 即从时序的角度考虑, 将患者随时间周期而发生细微变化的 MRI 图像来扩充数据集。从实验的结果来看, 这对提升准确率有一定的帮助。

表 2 数据量对比表

方法	模式	AD	MCI	HC
初始	MRI	180	250	200
增广后	MRI	267	574	446

2.2 医学影像预处理

原始的 MRI 图像的数据格式是 DICOM, 除了包含脑部图像信息, 还包含病人的基本信息, 故在实验中需要将其转换成图片格式。本文利用 MATLAB 工具中专门处理 MRI 图像的函数包来读取 MRI 数据中的图像信息, 然后将其转换成图片格式。转化后的图像的大小为 256×256 且每个主体包含 100 片相同大小的

医学图像。由于 MRI 是灰度图像, Caffe 框架所需的输入数据是三通道的彩色图像所以需要把 MRI 图像转化成 RGB 三通图像。

实验选用的是大脑轴向的图像, 表 1 为本实验 AD、MCI、HC 的 MRI 数据集的相关信息。之前的研究都会对 MRI 图像进行标准化的预处理, 如将脑部图像分割成三种不同的组织例如灰质(GM)、白质(WM) 和脊髓液(CSF), 一般 GM 包含的信息比较多, 于是大多数的实验只使用 GM 来进行分类, 但实验结果往往不是很理想。从而可以判断出对脑部图像的分割会影响分类的准确性。本文不对图像做任何更深层次的预处理, 由于这些处理有可能会破坏图像某些潜在的信息, 或者导致某些重要的信息缺损。

3 面向 MCI 图像识别的深度学习神经网络分类器(MCINet)

深度学习是机器学习的一个分支, 目的是为建立可以模仿人脑进行分析学习的神经网络。深度学习包含两个重要特点, 其中一个自动提取特征它与传统的人工提取特征有很大区别。另外一个特点通过组合底层特征来形成更加抽象的高级特征, 例如, 在计算机视觉领域, 深度学习算法从原始图像学习到一个底层特征, 然后在此基础上, 通过线性或者非线性组合来获得一个高层次的表达。神经网络主要分为三层, 分别为输入层、隐含层和输出层。传统神经网络一般只有两到三层比如 BP 网络和 DBN 网络, 而卷积神经网络的层数至少在四层以上, 这也是它能进行深度学习的原因。深度学习的核心是特征学习, 旨在通过分层网络获取分层次的特征信息, 从而解决以往需要人工设计特征的重要难题。深度学习是一个框架, 包含多个重要算法, 例如, Convolutional Neural Networks(CNN) 卷积神经网络、AutoEncoder 自动编码器、Sparse Coding 稀疏编码、Restricted Boltzmann Machine(RBM) 限制波尔兹曼机、Deep Belief Networks(DBN) 深信度网络、Recurrent neural Network(RNN) 多层反馈循环神经网络。现今, 深度学习已经被应用在多个领域, 其中就包括各种医学图像的分类。对于不同问题(图像、语音、文本), 需要选用不同网络模型才能达到理想的效果。基于本文是对图像分类的性质, 故采用 CNN 最为合适。CNN 一般是由多个卷积层、池化层和全连接层组成的。基于此本文实验采用的 MCINet 网络模型, 且它的网络结构相对简单, 它的结构及参数如图 4 所示, 它有 8 层网络结构(忽略激活函数、池化、LRN、Dropout 层), 有 5 个卷积层和 3 个全连接层。第一卷积层使用大小为 11×11 的卷积核, 步长为 4; 第二卷积层使用 5×5 的卷积核大小, 步长为 1; 剩余卷积层的卷积核都是 3×3 , 步长为 1。激活函数为 ReLU, 池化层使用重叠的最大池化, 大小为 3×3 , 步长为 2。在全连接层增加了 Dropout。

5×5 的卷积核大小, 步长为 1; 剩余卷积层的卷积核都是 3×3 , 步长为 1。激活函数为 ReLU, 池化层使用重叠的最大池化, 大小为 3×3 , 步长为 2。在全连接层增加了 Dropout。

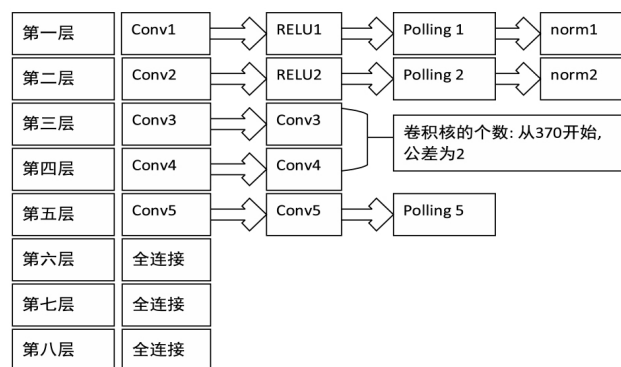


图4 算法框架

研究表明: 诊断 AD 的关键部分特征主要有海马体、颞叶、扣带回等区域。而且研究发现卷积层第三层和第四层提取的特征的能力最强, 故为了更准确地提取海马体、颞叶等区域的特征, 合适的卷积核的个数就显得尤为重要, 因此本实验主要是第三层和第四层卷积核的个数进行改进。主要过程是将第三、四层卷积核的个数, 从 370 开始做公差为 2 的批处理, 到 410 为止。通过对比发现当卷积核的数量为 398 的时候准确率达到最高。图 4 为该模型的算法框图, 表 3 为 MCINet 模型的参数说明。

表3 MCINet 的模型

层数	输出	卷积核	步长	卷积核数量
卷积层 1	55×55	11×11	4	96
池化层 1	27×27	3×3	2	96
卷积层 2	27×27	5×5	2	256
池化层 2	13×13	3×3	2	256
卷积层 3	13×13	3×3	1	398
卷积层 4	13×13	3×3	1	398
卷积层 5	13×13	3×3	1	256
池化层 3	6×6	3×3	2	256
全连接层 1	4 096	/	/	/
全连接层 2	4 096	/	/	/
全连接层 3	1 000	/	/	/

4 深度迁移学习

本文数据集的规模仍然不足以训练出好的模型, 故实验采用了迁移学习(Transfer Learning)^[16]的策略。迁移学习是把已训练好的模型参数迁移到新的模型来帮助新模型训练, 这是因为大部分数据或任务是存在相关性的。通过迁移学习我们可以将已经学到的模型

参数通过某种方式和新模型进行共享从而加快并优化模型的学习效率,而不用像大多数网络那样从零学习。值得一提的是,迁移学习并不局限于减少训练数据的规模,还可以有效避免过度拟合(Over-fitting),即建模数据超出了待解问题的基本范畴,一旦用训练数据之外的样例对系统进行测试,就很可能出现无法预料的错误。但由于迁移学习允许模型针对不同类型的数据展开学习,因此其在捕捉待解问题的内在联系方面的表现也就更优秀。本文在算法方面进行的改进主要是先将 MCINet 网络预训练 ImageNet 数据得到的初始化权重用于训练 MRI 数据集。本文主要对卷积层前两层运用迁移学习的技术,即将训练好的权重迁移到本网络的卷积层前两层。MCINet 模型剩下的其他层使用随机初始化即用本文的 MRI 数据集训练 MCINet,如图 5 所示。其中在反向传播(Back Propagation)的过程中,一般有两种方法可以选择:(1)把迁移过来的前 n 层冻结(frozen),也就是在训练 MCINet 模型时不改变这 n 层的权重值;(2)不冻结这 n 层,而是不断调整这些权重的值也称微调(fine-tune)。选择这些方法的前提是数据集的大小和前 n 层的参数个数,如果数据集很小,而参数个数很多,为了防止过拟合,一般会采用冻结的方法,反之,采用 fine-tune。故本文实验防止过拟合采用的方法是将迁移过来的前两层冻结,用本文 MRI 数据集训练模型剩下的层数。

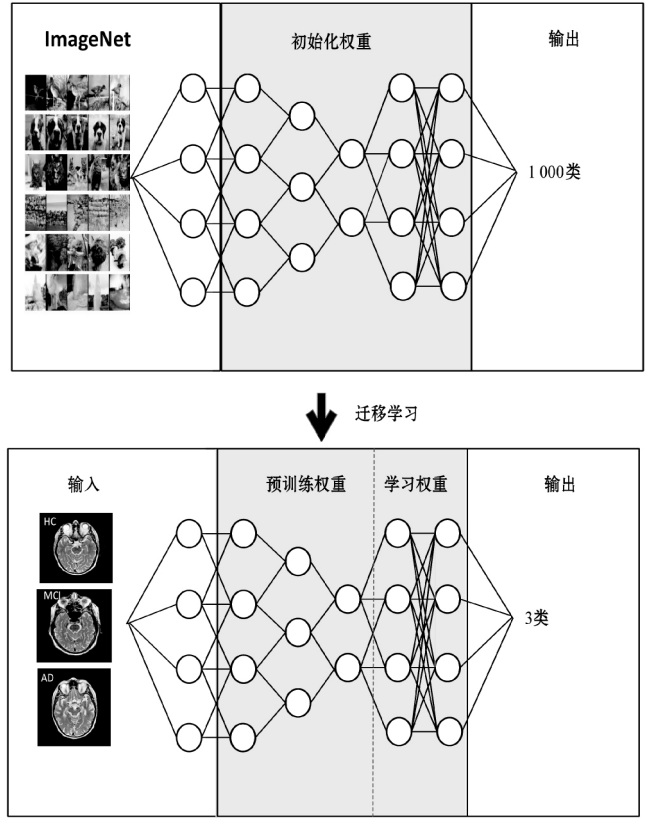


图 5 迁移学习算法框图

5 实验结果与分析

本实验采用的卷积神经网络是通过 Caffe 框架实现的。该框架是用 C++ 语言编写的,可通过软件 VS2013 查看,并通过 MATLAB 软件实现卷积层的特征可视化。

5.1 定量分析

实验准备了三组数据集,分别是 AD vs. MCI、HC vs. MCI、AD vs HC。我们把 MRI 数据分成两类:10% 为测试集,剩余的为训练集。每个主体包含 100 片切片,总的切片数量如表 1 所示。然后选取如图 2 所示的片数作为训练集和测试集。


算法 1 是不考虑迁移学习的方法,用 MCINet 模型去训练数据集。算法 2 是将迁移学习与 MCINet 模型相结合去训练数据集。

表 4 是两种算法训练数据后得到的准确率的对比,由表中明显可以看出算法 2 要优于算法 1。

表 4 算法比较

准确率	MCI vs. AD	HC vs. MCI	AD vs. HC
算法 1	82.0	89.6	88.5
算法 2	86.8	97.0	95.0

图 6 分别是通过 MCINet 再结合迁移学习来训练三个训练集得到的 loss 曲线和 accuracy 曲线。由 loss 曲线可知,loss 在整体上呈下降趋势,最后维持在 0 附近,accuracy 曲线开始呈上升曲线,最后维持在一定的范围内,由此可知实验的曲线是满足深度学习曲线的规律。



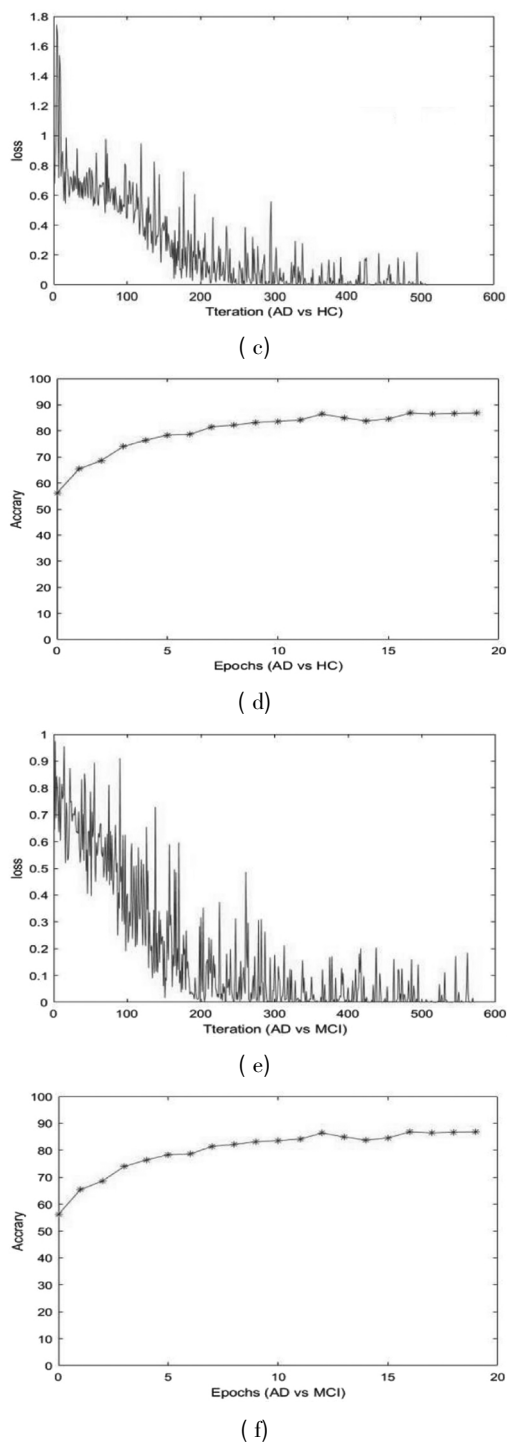


图6 数据集的 loss 曲线与 accuracy 曲线

5.2 定性分析

在训练数据前, Caffe 框架除了需要将输入数据转换成 LMDB 或者 LevelDB 的格式外, 还要计算训练集的均值文件, 这是因为图像减去均值后, 在进行训练或者测试时, 会大大提高速度和精度, 而这往往是深度学习进行大量计算所需要达到的效果。图7是 MCI vs HC 这




图7 均值图

个训练集下的均值可视化。

图8是卷积神经网络各个卷积层的特征图的可视化, 这是将一张 MCI 的图片进行测试而得到的。通过可视化这些特征图可以更加清楚地了解卷积神经网络的工作过程。




图8 特征图

5.3 方法对比

表5是将前人研究实验的分类准确率与本文实验结果进行的对比。实验分别对三个数据集即 AD vs. HC, MCI vs. HC, AD vs. MCI 的结果进行比较。从表中可以看出我们实验的方法明显优于前人研究的方法, 分别达到了 95.0%、97.0%、86.8%。

表5 实验准确率对比

方法	AD vs. HC	MCI vs. HC	AD vs. MCI
文献[13]	73.75	76.4	NA
文献[14]	87.12	72.89	84.81
文献[15]	91.8	79.5	NA
文献[9]	95.9	85.0	83.7
本文方法	95.0	97.0	86.8

6 结 语

本文在数据量一定的情况下, 分别从数据和算法这两个方面进行改进来提高分类的准确率。首先, 通过数据增广的方式扩充 MRI 数据集的规模。然后采用一种针对 MRI 图像识别的端到端的深度神经网络分类器对 AD、MCI、HC 分类。受数据集规模的限制, 本实验将迁移学习技术与深度神经网络分类器相结合。为了验证迁移学习的有效性, 本文通过实验对比, 一种完全采用深度神经网络分类器对 MRI 数据集进行训练, 另一种引用迁移学习技术, 即将训练公共数据集 ImageNet 得到的权重迁移到本网络的卷积层前两层, 剩下的其他层用 MRI 数据集训练。从实验的结果来看, 与迁移学习结合的深度神经网络分类器的方

法更有效。但是本文仍然存在不足,比如分类的准确率仍需要进一步的提高。以后工作会考虑训练集不仅仅用 MRI 数据也尝试用信息量更丰富的 DTI 数据,或者采用三维的卷积神经网络对 3D 的医学图像进行训练,而且会继续考虑信息量最丰富的片数是否可以自动挑选。

参 考 文 献

- [1] Brosch T, Tam R. Manifold Learning of Brain MRIs by Deep Learning [C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. 2013: 633–640.
 - [2] Gray K R. Machine learning for image-based classification of Alzheimer's disease [D]. Imperial College London, 2012.
 - [3] Gupta A, Maida A S, Ayhan M. Natural Image Bases to Represent Neuroimaging Data [C]//International Conference on Machine Learning. 2013: 987–994.
 - [4] Klöppel S, Stonnington C M, Chu C, et al. Automatic classification of MR scans in Alzheimer's disease [J]. Brain, 2008, 131(3): 681–689.
 - [5] Liu M, Zhang D, Adelimosabbab E, et al. Inherent Structure Based Multi-view Learning with Multi-template Feature Representation for Alzheimer's Disease Diagnosis [J]. IEEE Transactions on Biomedical Engineering, 2016, 63(7): 1473–1482.
 - [6] Liu F, Shen C. Learning Deep Convolutional Features for MRI Based Alzheimer's Disease Classification [EB]. arXiv: 1404.3366, 2014.
 - [7] Zu C, Jie B, Liu M, et al. Label-aligned multi-task feature learning for multimodal classification of Alzheimer's disease and mild cognitive impairment [J]. Brain Imaging & Behavior, 2016, 10(4): 1148–1159.
 - [8] Payan A, Montana G. Predicting Alzheimer's disease: a neuroimaging study with 3D convolutional neural networks [EB]. arXiv: 1502.02506, 2015.
 - [9] Suk H I, Wee C Y, Lee S W, et al. State-space model with deep learning for functional dynamics estimation in resting-state fMRI [J]. Neuroimage, 2016, 129: 292–307.
 - [10] Coates A, Ng A Y. The Importance of Encoding Versus Training with Sparse Coding and Vector Quantization [C]//Proceedings of the 28th International Conference on Machine Learning, ICML 2011, Bellevue, Washington, USA, June 28–July 2, 2011. Omnipress, 2011.
 - [11] Bo L, Ren X, Fox D. Multipath Sparse Coding Using Hierarchical Matching Pursuit [C]//Proceedings of the 2013 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2013: 660–667.
 - [12] Yang J, Li S, Xu W. Active Learning for Visual Image Classification Method Based on Transfer Learning [J]. IEEE Access, 2018, 6: 187–198.
 - [13] Islam J, Zhang Y. A Novel Deep Learning Based Multi-class Classification Method for Alzheimer's Disease Detection Using Brain MRI Data [C]//International Conference on Brain Informatics. Springer, Cham, 2017: 213–222.
 - [14] Khedher L, J. Ramírez, J. M. Górriz, et al. Independent Component Analysis-Based Classification of Alzheimer's Disease from Segmented MRI Data [C]//International Workshop on the Interplay Between Natural & Artificial Computation. Springer, Cham, 2015.
 - [15] Tong T, Gray K, Gao Q, et al. Multi-modal classification of Alzheimer's disease using nonlinear graph fusion [J]. Pattern Recognition, 2017, 63: 171–181.
-
- (上接第 132 页)
- [13] Matsumoto K, Ren F, Kuroiwa S. Emotion Estimation System Based on Emotion Occurrence Sentence Pattern [J]. Journal of Natural Language Processing, 2006, 14(3): 902–911.
 - [14] 马莉,唐素勤,陈立娜等.改进的基于句模匹配算法的问句理解方法 [J]. 计算机工程, 2009, 35(20): 50–52.
 - [15] 周颖,任赞.应用题自动解答系统中“有”字句的语义理解 [J]. 中国电化教育, 2011(4): 116–120.
 - [16] Iwane N, Takeuchi A, Otsuki S. A network intelligent educational system for arithmetic word problems [J]. Systems and Computers in Japan, 1997, 28(10): 30–39.
 - [17] 马玉慧,谭凯,尚晓晶.基于语义句模的语义理解方法研究 [J]. 计算机技术与发展, 2012, 22(10): 117–120, 124.
 - [18] 石翠.依存句法分析研究综述 [J]. 智能计算机与应用, 2013, 3(6): 47–49.
 - [19] Giguet E, Vergne J. Syntactic Analysis of Unrestricted French [EB]. oai: CiteSeerX. psu: 10.1.1.27.5366, 2007.
 - [20] Schröder I, Menzel W, Foth K, et al. Modeling Dependency Grammar With Restricted Constraints [J]. T. A. L., 2000, 41(1): 113–142.
 - [21] 刘海涛,赵悱怡.基于树库的汉语依存句法分析 [J]. 模式识别与人工智能, 2009, 22(1): 17–21.
 - [22] Wang W, Stolcke A, Harper M P. The use of a linguistically motivated language model in conversational speech recognition [C]//IEEE International Conference on Acoustics. IEEE, 2004.
 - [23] Hacioglu K. Semantic role labeling using dependency trees [C]//International Conference on Computational Linguistics. Association for Computational Linguistics, 2004: 1273.
 - [24] 任彬,车万翔,刘挺.基于依存句法分析的社会媒体文本挖掘方法——以饮食习惯特色分析为例 [J]. 中文信息学报, 2014, 28(6): 208–215.
 - [25] 朱晓亚,范晓.二价动作动词形成的基干句模 [J]. 语言教学与研究, 1999(1): 111–122.
 - [26] 吴林静,劳传媛,范桂林,等.一种规则与统计相结合的应用题句子语义角色识别方法 [J]. 计算机应用研究, 2018, 35(8): 2299–2303.